

מטלת סיכום בלמידת מכונה – חלק 2:

מודל חיזוי דירוג סרטים

מגישות: מרים דינאי 212296099 | הילה הברשטט 032540668

1. תיאור הדאטה המעובד וטבלת הפיצ'רים

בשלב הראשון עבדנו עם קובץ נתונים גולמי הכולל 133,884 תצפיות של סרטים. בשלב עיבוד הנתונים הראשוני, הוסרו מסט האימון סרטים חסרי דירוג במשתנה המטרה (averageRating), כך שנותרו עם 115,560 תצפיות מוגדרות לטובת שלב הלמידה.

במסגרת שלב הנדסת הפיצ'רים (Feature Engineering), פיתחנו 9 פיצ'רים חדשים מעבר לעמודות המקוריות, כדי לעזור למודל לזהות קשרים בנתונים ולפצות על מידע שחסר.

טבלת פיצ'רים (Feature Engineering)

שם הפיצ'ר	תיאור/מוטיבציה	סוג
num_genres	ספירת כמות הז'אנרים המקושרים לסרט מתוך מחרוזת genres סרטים מרובי ז'אנרים עשויים לפנות לקהל יעד רחב יותר	נומרי
primary_genre	חילוץ הז'אנר הראשון מהרשימה. מאפשר למודל להתייחס לז'אנר המוביל כמשתנה קטגוריאלי (יעבור One Hot Encoding)	קטגוריאלי
is_drama	סימון בינארי האם הסרט מכיל את הז'אנר דרמה. דרמות נוטות לקבל הערכה ביקורתית גבוהה יותר	בינארי
is_comedy	סימון בינארי לז'אנר קומדיה, לרוב סרטים קלילים יותר	בינארי
is_documentary	סימון בינארי לז'אנר דוקומנטרי. זיהינו שסרטי דוקו מקבלים דירוגים גבוהים משמעותית	בינארי
is_US	בדיקה האם ארה"ב מופיעה בעמודת Country. ארה"ב היא מעצמת הפקות המשפיעה על סגנון הקולנוע והתקציב	בינארי
num_countries	ספירת כמות המדינות המעורבות. משמש כמדד עקיף לגודל ההפקה ורוחב התקציב (במקום עמודת התקציב החסרה)	נומרי
plot_length	ספירת מספר המילים בתקציר העלילה. מבוסס על ההשערה שתקציר מושקע וארוך יותר מצביע על שיווק רציני יותר	נומרי
release_decade	חלוקה של שנת היציאה (startYear) לעשורים שלמים. מונע רעש של שנים ספציפיות ועוזר למודל לזהות מגמות היסטוריות	נומרי מורכב (Binning)

2. סעיף prepare_data ומניעת Data Leakage

פונקציית הסינון וההכנה של הקובץ נבנתה תחת prepare_data שמטרתה להכין את קובץ הנתונים של הסרטים לצורך אימון המודל, תוך הסרת עמודות שעלולות לגרום לזליגת מידע (Data Leakage) וטיפול

בערכים חסרים. כתבנו אותה כך שתעבוד בצורה דטרמיניסטית על סט מלא או על שורה בודדת כדי שתוכל לעבוד גם על סט נתונים חיצוני. השלבים כללו:

- ניקוי מחרוזות מרווחים, גרשיים וסוגריים בעמודות
- המרת עמודות למספרים והחלפת ערכים שגויים (כמו \N או שנות יציאה שליליות/אפס) בNaN
- הסרת ערכי אינסוף למניעת שגיאות בריצה

במהלך שלב חקירת הנתונים, זיהינו כי נתון התקציב (budget) חסר בכ-80% מהמקרים. מבדיקתנו עולה כי החוסר נובע ממגבלות טכניות בעת איסוף הדאטה, ולא ממאפיינים פנימיים של הסרטים עצמם. כדי לקבוע את דרך הטיפול המיטבית, השונו את ביצועי המודל על פני שלושה מדדים (R^2 , RMSE, MAE) בין שלוש גרסאות שונות: גרסה A (הכוללת את משתנה התקציב), גרסה C (המוסיפה אינדיקטור לחוסר הנתון), וגרסה B (המסירה את משתנה התקציב לחלוטין)

מדד	גרסה A (עם משתנה Budget)	גרסה C (תוספת אינדיקטור חסר)	גרסה B (הסרת משתנה Budget)
RMSE	1.1578	1.1568	1.1459
MAE	0.8913	0.8902	0.8783
R^2	0.1978	0.1992	0.2143

מהתוצאות עלה בבירור כי גרסה B ללא עמודת budget היא המנצחת, היא מציגה את השגיאות הנמוכות ביותר ואת אחוז הסבר השונות הגבוה ביותר (R^2). לכן, החלטנו להסיר את המשתנה לחלוטין, מכיוון שביצוע השלמת נתונים בהיקף חוסר כה נרחב היה מכניס רעש אקראי למערכת ופוגע בדיוק של המודל.

מניעת Data Leakage (זליגת נתונים):

וידאנו מניעת זליגה בשני מישורים:

1. **הסרת משתנים עתידיים:** הסרנו את עמודות numVotes, averageRating, BoxOfficeI, מכיוון שהם מתגלים רק לאחר יציאת הסרט לאקרנים.
2. **מניעת זליגה:** לא ביצענו השלמת חסרים (Imputation) או נרמול (Scaling) על הנתונים הגולמיים. במקום זאת, השתמשנו באובייקט Pipeline של ScikitLearn (בצירוף ColumnTransformer). ה-Pipeline הופעל בתוך תהליך ה-Cross Validation, מה שמבטיח שהחציון להשלמת חסרים וממוצעי הנרמול מחושבים אך ורק על ה-Training Fold בכל איטרציה, ולא "רואים" את הנתונים מקבוצת המבחן (Validation Fold).

3. השוואת מודלים וביצועים (Fold CV10)

אימנו שני מודלים באמצעות GridSearchCV על פני 10 קיפולים (Fold CV10). המודל הראשון הוא Elastic Net, והמודל השני שבחרנו הוא Random Forest. **בחרנו ב Random Forest מהסיבות הבאות:**

1. משלים את Elastic Net אחד לינארי, אחד לא לינארי. הניגוד נותן השוואה מעניינת.
2. טוב יותר עם הרבה ערכים חסרים- יש לנו 86% חסרים ב-budget, Random Forest פחות רגיש לזה מאשר Decision Tree יחיד.
3. פחות עלול ל Decision Tree overfitting יחיד, ולכן יציב יותר.
4. בד"כ נותן RMSE נמוך משמעותית ממודל לינארי על דאטה כזה.

תוצאות (ממוצע על 10 קיפולים):

מדד ביצוע / פרמטר	מודל Elastic Net	מודל Random Forest	המודל המנצח במדד
RMSE ממוצע	1.1459±0.0093	1.1191±0.0090	Random Forest שגיאה נמוכה יותר
MAE ממוצע	0.8783±0.0064	0.8540±0.0063	Random Forest שגיאה נמוכה יותר
R2 ממוצע	0.2143	0.2506	Random Forest הסבר שונות גבוה יותר
הפרמטרים הנבחרים	alpha=0.01l1_ratio=0.2	n_estimators=100max_depth=10min_samples_leaf=5	

המסקנה, מודל Random Forest ניצח והציג ביצועים טובים יותר בכל המדדים (RMSE נמוך יותר R^2 גבוה יותר), עם סטיית תקן קטנה שיכולה להעיד על יציבות מסוימת לאורך כל הקיפולים. כתוצאה מכך, הניתוחים הבאים מבוססים עליו כמודל המוביל.

4. ניתוח חשיבות פיצ'רים (Feature Importance)

ביצענו חילוץ וניתוח של חמשת הפיצ'רים המשפיעים ביותר בכל אחד מהמודלים. עבור מודל Elastic Net החשיבות נקבעה על פי ערכם המוחלט של המקדמים המנורמלים הסטנדרטיים (coefficients). עבור מודל Random Forest החשיבות חולצה באמצעות מדד Feature Importance המובנה (Gini Importance) בשילוב חישוב כיווניות באמצעות קורלציה.

חמשת הפיצ'רים המובילים והשפעתם:

1. Elastic Net (לפי מקדמים מנורמלים):
 - cat_primary_genre_Horror (כיוון השפעה: שלילי חזק, מקדם: -0.7602)
 - num_is_documentary (כיוון השפעה: חיובי חזק, מקדם: +0.4730)
 - cat_primary_genre_Action (כיוון השפעה: שלילי, מקדם: -0.2749)
 - num_runtimeMinutes (כיוון השפעה: חיובי, מקדם: +0.2378)
 - num_is_drama (כיוון השפעה: חיובי, מקדם: +0.2005)
2. Random Forest (לפי מדד חשיבות וקורלציה):
 - num_is_documentary (חשיבות: 0.3233, כיוון השפעה: חיובי)
 - num_runtimeMinutes (חשיבות: 0.1805, כיוון השפעה: חיובי)
 - num_is_drama (חשיבות: 0.1796, כיוון השפעה: חיובי)
 - num_startYear (חשיבות: 0.0987, כיוון השפעה: שלילי)
 - cat_primary_genre_Horror (חשיבות: 0.0889, כיוון השפעה: שלילי)

שני המודלים מסכימים באופן גורף על המגמות העיקריות: סרטים דוקומנטריים, סרטי דרמה ואורך הסרט משפיעים באופן חיובי על הדירוג. לעומת זאת, סרטי אימה מורידים משמעותית את הדירוג בממוצע. ההבדל העיקרי הוא ש Random Forest ייחס חשיבות גם לשנת היציאה (startYear קורלציה שלילית), מה שמרמז שסרטים ישנים יותר נוטים לקבל דירוגים גבוהים יותר מאשר הפקות לסרטים חדשים.

5. ניתוח שגיאות (Error Analysis)

בסעיף זה ביצענו ניתוח איכותי וכמותי של התחזיות החריגות, אשר הופקו באמצעות תהליך CV (cross_val_predict). שימוש בפונקציה זו קריטי על מנת למנוע זליגת נתונים וחיזוי מוטא, ובכך מטיב לייצג את יכולת ההכללה של המודל על נתונים חדשים.

חילוץ ערכי הקצה/חריגים (Outliers)

מתוך התחזיות ב-Cross Validation של המודל המוביל (Random Forest), חילצנו את 10 הסרטים בעלי חיזוי היתר הגדול ביותר (Overpredictions) ואת 10 הסרטים בעלי חיזוי החסר הגדול ביותר (Underpredictions), סך הכל 20 סרטים חריגים.

ניתוח איכותי של מקרי בוחן ספציפיים

להלן ניתוח של חמישה סרטים חריגים בולטים, המשלב את הרקע ההפקתי של היצירה אל מול מגבלות הנתונים של המודל:

- **"Justin Bieber: Always Believing" (שנת 2012)**
נתוני חיזוי: 7.11 | בפועל: 1.0 (Overprediction)
זהו סרט תיעודי מוזיקלי העוקב אחר סיבובי ההופעות והתופעה התרבותית סביב זמר הפופ ג'סטין ביבר. המודל זיהה את השילוב הז'אנרי של Documentary, Music כסיגנל לאיכות גבוהה והפיק תחזית אופטימית. עם זאת, המודל לא רואה את הקשר התרבותי של אותה תקופה, בה היצירה ספגה מתקפת דירוגים שלילית מאסיבית ומתוזמנת מצד אנטי מעריצים ברשת, תופעה חברתית שאינה מיוצגת במשתני המבנה של הדאטה.
- **"Sonnim1 Cheobeonijae lyagi" (שנת 2011)**
נתוני חיזוי: 4.24 | בפועל: 9.1 (Underprediction)
ניתוח השגיאה: מדובר בסרט מתח ואימה פסיכולוגי עצמאי מדרום קוריאה, אשר זכה לאהדה פנומנלית בקרב חובבי קולנוע זר וסרטי קאלט בנישה זו. מאחר שהסרט מתויג תחת הז'אנרים Horror, Thriller, המודל הפעיל את החוקיות הכללית של המאגר הקונסט ז'אנרים אלו בשל ממוצע ציונים נמוך. המודל נתן ציון נמוך רק כי מתויג תחת סרט אימה, המודל פחות מדויק בסרטי נישה או קאלט, כיוון שהוא מסתמך רק על הז'אנר הכללי.
- **"Rape of the Soul" (שנת 2006)**
נתוני חיזוי: 7.71 | בפועל: 1.7 (Overprediction)
ניתוח השגיאה: יצירה זו היא סרט תיעודי עצמאי בעל אופי היסטורי חברתי, העוסק בנושאים נפוצים ושנויים במחלוקת ציבורית עזה. בהתאם לחוקיות הגורפת של "סרט דוקומנטרי שווה איכות", המודל הניח שמדובר ביצירה מוערכת וחזה תחזית גבוהה. בפועל, המודל חסר גישה לתוכן הסרט או לקיומו של שיח ציבורי מקומם במציאות, אשר הוביל להצבעת מחאה נגד הסרט ולהורדת הדירוג האמיתי שלו לרמה נמוכה.
- **"Akkada Varu Ikkada Unnaru" (שנת 2024)**
נתוני חיזוי: 5.21 | בפועל: 9.1 (Underprediction)
ניתוח השגיאה: סרט אימה מודרני המגיע מתעשיית הקולנוע הדוברת שפת טלוגו (תעשיית "טוליווד" מהודו). הסרט זכה להצלחה קופתית גדולה ולביקורות טובות מצד קהל המעריצים המקומי שמילא את אולמות הקולנוע. המודל לא יכול ללמוד נתון זה על פי המאפיינים המבניים והז'אנריים הרגילים של סרטי אימה סטנדרטיים, המודל לא מכיר ולא רגיש להבדלים בין השווקים.
- **"Zen Comedy" (שנת 2023)**
נתוני חיזוי: 5.62 | בפועל: 9.8 (Underprediction)
ניתוח השגיאה: סרט קומדיה עצמאי שזכה לציון אמיתי כמעט מושלם במאגר. ככלל, סרטי קומדיה בדאטה נוטים להתכנס לאזור הציון הבינוני 6, ועל כן המודל נתן תחזית ממוצעת. המודל לא ידע שמדובר בסרט נישה קטן עם קבוצת מעריצים מושבעת, שנכנסו כולם לעמוד הסרט, נתנו לו ציונים מושלמים והקפיצו את הציון האמיתי ל-9.8, ללא קשר לחוקיות הז'אנרית הכללית.

זיהוי דפוסים בין Outliers

ניתוח מקיף של כלל 20 האאוטליירים חושף דפוס מערכתי ושיטתי ברור המפריד בין קבוצות הטעות:

- **ב Overpredictions** רובם המוחלט הם סרטי Documentary. המודל למד שסרטים תיעודיים מקבלים ציונים גבוהים, ולכן הוא מייצר תחזיות מנופחות מדי עבור סרטים תיעודיים גרועים, משעממים או סרטי שיווק יחסי ציבור מסחריים.

- **Underpredictions** רובם משתייכים לז'אנרים של אימה, פעולה וקומדיה. המודל קונס ז'אנרים אלו באופן מובנה בשל ממוצע נמוך בדאטה, ובכך הוא מחטיא יצירות מופת וסרטי קאלט שמצליחים להתעלות מעל הממוצע הז'אנרי הרגיל.

השוואה בין המודלים באוטליירים

- חפיפת חריגים (60%): מתוך 20 האוטליירים של כל מודל, 12 סרטים חופפים לחלוטין (בעיקר סרטי PR תיעודיים). הדבר מוכיח כי מקור השגיאה אינו במבנה של מודל ספציפי, אלא במגבלת הנתונים, לשני המודלים חסר מידע קריטי על איכות היוצרים (במאי, חברת הפקה) ומדדי הכרה חיצוניים (פרסים, ביקורות).
- דינמיקת השגיאות ופוטנציאל Ensemble: כאשר בוחנים את תפקוד המודלים על Outliers של המודל השני, עולה ממצא מעניין:

השוואת הביצועים על outliers:

Elastic NET outliers	Random Forest outliers	
4.777	5.132	שגיאה ב Random Forest
5.173	4.962	שגיאה ב Elastic Net

נמצא כי כאשר מודל אחד טועה קיצוני, השני נוטה למצב את הטעות (Elastic Net שומר על שמרנות לינארית, בעוד RF נוטה לפיצולים חדים). הפער הקטן (0.2-0.4) מעיד כי שילוב מודלים (Ensemble) ירסן שגיאות קצה, אך לא יפתור את הבעיה ללא הנדסת פיצ'רים חדשים.

שגיאות ייחודיות:

Random Forest מתקשה במקרי קצה של Runtime קיצוני (למשל סרט באורך 203 דקות), בשל חלוקות חדות (Splits) של משתנים רציפים.

Elastic Net נתן ציון נמוך בלכידת אינטראקציות שהן לא לינאריות מורכבות (כמו שילוב ז'אנרים נדיר של Fantasy Adventure, Comedy יחד), מעצם היותו מודל לינארי תוספי.

הצעות לשיפור ופיצ'רים חדשים:

על בסיס הניתוח, להלן 3 הצעות לפיצ'רים שהיו מסייעים למודל להתמודד עם השגיאות:

1. ממוצע הדירוגים ההיסטורי של הבמאי (מנתוני IMDb) חישוב ממוצע הציונים של סרטי הבמאי הקודמים (למניעת זליגה). הציון הנמוך של במאי יחסי ציבור יקזז חיזוי יתר בסרטים דוקומנטריים, וציון גבוה של במאי נישה ימנע חיזוי חסר בסרטי קאלט.
2. תקציב שיווק והיקף הקרנת פתיחה (מנתוני Box Office Mojo / The Numbers), מספר בתי הקולנוע בסוף השבוע הראשון ותקציב הפרסום. היקף השיווק משקף את אמון המפיקים באיכות הסרט. היעדר הפצה לקולנוע ומעבר ישיר לסטרימינג יסמנו סרטי PR זולים ויקזזו את החיזוי הגבוה שלהם.

3. הכרה תעשייתית פרסים ומועמדות (מנתוני IMDb/מאגרי פסטיבלים). משתנה בינארי או קטגורי המסמן מועמדות או זכייה בפרסים מרכזיים (אוסקר, באפט"א) או הקרנה בפסטיבלים נחשבים (קאן, סאנדנס). פיצ'ר זה מהווה סיגנל איכות חיצוני של מומחים, שיוריד את הציון לסרטי PR מסחריים חסרי הכרה ויעלה לסרטי קאלט וסרטים זרים המצליחים בפסטיבלים.

6. ניתוח הוגנות (Fairness Analysis)

בחנו את ביצועי המודל המוביל Random Forest בשני חתכים שונים:

לפי ז'אנר (5 הנפוצים): נמצאו פערים משמעותיים בין הז'אנרים Action. הוא הז'אנר הקשה ביותר לחיזוי (RMSE של 1.24, כ-10% מעל הממוצע הכללי של 1.12). זה תואם את הממצאים מ error analysis רוב ה underpredictions היו סרטי Action/Horror בהם המודל לא הצליח לזהות סרטי קאלט. לעומת זאת, Crime ו Documentary הם הז'אנרים הקלים ביותר לחיזוי (RMSE של 1.0).

הז'אנרים הנפוצים 5: ['Drama', 'Comedy', 'Action', 'Documentary', 'Crime']

ביצועים לפי ז'אנר

	RMSE	MAE	n_samples
genre			
Drama	1.0698	0.8163	33564.0
Comedy	1.1211	0.8571	27975.0
Action	1.2360	0.9643	13987.0
Documentary	1.0107	0.7417	10496.0
Crime	1.0001	0.7576	6390.0


לפי עשור יציאה: נמצא דפוס מובהק ועקבי ככל שהסרט חדש יותר, כך המודל פחות מדויק. סרטים משנות ה-40-30 מקבלים RMSE של כ-0.79, ואילו סרטים מ-2020 מקבלים RMSE של 1.25. שיפור של למעלה מ-60% בשגיאה עבור סרטים חדשים. הגרסה נמצאת בעקביות מ-1930 ועד 2020 ללא יוצאי דופן.

עשורים שנבדקו: [1910, 1920, 1930, 1940, 1950, 1960, 1970, 1980, 1990, 2000, 2010, 2020]

ביצועים לפי עשור

	RMSE	MAE	n_samples
decade			
1910.0	0.8457	0.6293	171.0
1920.0	0.9787	0.7319	785.0
1930.0	0.7948	0.5897	3121.0
1940.0	0.7909	0.5938	3292.0
1950.0	0.8616	0.6584	4602.0
1960.0	0.9888	0.7825	6208.0
1970.0	1.0220	0.8044	7969.0
1980.0	1.0593	0.8331	9631.0
1990.0	1.0773	0.8446	10213.0
2000.0	1.1520	0.8799	17555.0
2010.0	1.1868	0.9006	33605.0
2020.0	1.2490	0.9533	18405.0

גרף השוואה:



7. ניתוח חשיבות פיצ'רים (Feature Importance)

זיהינו את חמשת הפיצ'רים החשובים ביותר לכל מודל: עבור מודל Elastic Net חשיבות חולצה לפי המקדמים הסטנדרטיים (coefficients), ועבור מודל Random Forest היא חולצה באמצעות מדד Feature Importancen המובנה (Gini Importance).

שני המודלים מציגים הסכמה גורפת על 4 מתוך 5 הפיצ'רים המובילים שלהם, מה שמחזק את עקביות הממצאים:

1. `is_documentary` (כיוון השפעה חיובי בשניהם) הפיצ'ר החשוב ביותר. סרטים תיעודיים נוטים לקבל ציונים גבוהים יותר במוצע במאגר הנתונים.
2. `runtimeMinutes` (כיוון השפעה חיובי בשניהם) סרטים בעלי משך זמן ארוך יותר נוטים לקבל ציונים גבוהים יותר, מה שמעיד בספרות על השקעה הפקתית גדולה יותר.
3. `is_drama` (כיוון השפעה חיובי בשניהם) מאשש את התובנה שסרטי דרמה זוכים להערכה חיובית ויציבה מצד הקהל.
4. `primary_genre_Horror` (כיוון השפעה שלילי בשניהם) המודלים מורידים את התחזית לסרטי אימה באופן עקבי, ממצא התומך ישירות בנטייה לחיזוי חסר שראינו בניתוח השגיאות (סעיף 5).

נקודות הפיצול בין המודלים (איפה הם נחלקים ולמה?)

- **Elastic Net** מעניק משקל גבוה במיוחד לפיצ'ר `genre_Action_primary` (מקדם שלילי של 0.27). כמודל לינארי, הוא מזהה קשר לינארי ישיר וברור בין ז'אנר הפעולה לבין ציונים נמוכים במאגר, ולכן מייחס לו חשיבות רבה במשוואה התוספתית שלו.
- **Random Forest** מעדיף להכניס לחמישייה המובילה את המשתנה הרציף `startYear`. המודל הלינארי (Elastic Net) התעלם ממנו כיוון שהקורלציה הלינארית הגולמית של שנת היציאה עם משתנה המטרה נמוכה מאוד (0.03). עם זאת, Random Forest מסוגל ללמוד קשרים מורכבים ולא לינאריים דרך פיצולים מרובים בסביבת העצים, ובכך הוא מחלץ ממנו מידע משמעותי על ההבדלים הדינמיים בין סרטים מתקופות שונות.

מסקנות ומגבלות

ראינו שניתן לחזות דירוגי סרטים מראש באמצעות משתנים יבשים ומבניים בלבד (ז'אנר, אורך, שנת יציאה) עד לרמת דיוק טובה מאוד של פחות מנקודת דירוג אחת במוצע $MAE \sim 0.85$ מודל Random Forest הוכח כמתאים ומדויק יותר מהרגרסיה הלינארית, כיוון שהוא מסוגל לתפוס את המבנה הלא לינארי ואת האינטראקציות המורכבות שבין הז'אנרים השונים למשכי הזמן של הסרטים.

עם זאת, הדירוג מושפע מאוד ממשתנים שאינם קיימים בדאטה, כמו איכות המשחק, ביקורות ברשת או פסטיבלים. מגבלה מרכזית בפרויקט נבעה מהצורך להסיר לחלוטין את משתנה התקציב (budget) בשל

היקף חוסרים קיצוני של כ 80%, החלטה שהייתה הכרחית כדי למנוע הזנת רעש אקראי למערכת, אך שללה מהמודל משתנה כלכלי חשוב.

8. שימוש ב (AI Usage Log)

במהלך העבודה נעזרנו בClaude וב Gemini לייעוץ בנושאים הבאים:

1. בקרת קוד Data Leakage התייעצות לגבי דרכים נכונות ליישום ColumnTransformer בתוך Pipeline כדי למנוע זליגת נתונים בתהליך Cross Validation. המודל ייעץ להשתמש בcross_validated להרצת מדדים מרובים ביעילות.
2. מידע על סרטים תוכן איכותי של חילוץ החריגים.
3. התמודדות עם ניקוי נתונים וערכים חסרים: התייעצנו האם לבצע Imputation לעמודת budget.
4. בהמלצת הAl (ולאחר שיחה עם ענת) החלטנו להסירה עקב 80% חוסרים.
4. הבנת כיוון ההשפעה (סעיף 7): התייעצנו כיצד למצוא קורלציות וכיווניות עבור Random Forest (שמספק רק חשיבות מוחלטת).
5. אימתנו את הקוד על ידי בחינת התוצאות מול Elastic Net וראינו שהמגמות תואמות.